Material explicativo

Lucas Amaral Taylor

Entregue em março de 2026

Este material explicativo tem como objetivo: registrar o processo de tratamento da base de dados, apresentação dos principais resultados da análise exploratória e aplicação da modelagem.

1. Informações gerais

A base fornecida está disponível no *Github* Wu (nd). O *dataset* possui 9994 linhas e 20 colunas, listadas a seguir: `Order ID`, `Order Date`, `Ship Date`, `Ship Mode`, `Customer ID`, `Customer Name`, `Segment`, `Country`, `City`, `State`, `Postal Code`, `Region`, `Product ID`, `Category`, `Sub-Category`, `Product Name`, `Sales`, `Quantity`, `Discount` e `Profit`.

Trata-se de uma base de dados de uma loja, Superstore, uma empresa varejista fictícia dos EUA. A empresa é especializada em móveis, materiais de escritório e produtos de tecnologia. O *dataset* fornece uma análise detalhada do desempenho da empresa de 2019 a 2022.

O trabalho compilado está estruturado da seguinte forma:

```
.
├── data
│   ├── data_processed
│   │   ├── SUPERSTORE_MODELAGEM.csv
│   │   └── SUPERSTORE_TRATADO.csv
│   └── data_raw
│       └── SUPERSTORE.csv
├── main.py
├── model
│   └── SUPERSTORE_CLUSTERING.csv
├── notebooks
│   ├── 01_exploracao_inicial.ipynb
│   ├── 02_outliers.ipynb
│   ├── 03_kmeans.ipynb
│   └── 04_temporal_series.ipynb
├── output
│   └── models_predict
│       ├── arima_cluster_0.joblib
│       ├── arima_cluster_1.joblib
│       ├── arima_cluster_2.joblib
│       └── kmeans_clustering.joblib
├── README.md
├── report
│   ├── notebook_01
│   ├── notebook_03
│   └── notebook_04
├── requirements.txt
└── src
    ├── build_model.py
    ├── predict.py
    └── utils.py
```

onde:

- `data/`: Armazena os dados do projeto.
  - `data_raw/`: Contém os dados brutos, sem tratamento.
  - `data_processed/`: Contém os dados tratados e prontos para modelagem.
- `model/`: Contém artefatos intermediários de modelagem, como datasets com clusters atribuídos.
- `notebooks/`: Reúne notebooks de análise exploratória e experimentos (EDA, tratamento de outliers, clustering e séries temporais).
- `output/`: Armazena as saídas finais dos modelos.
  - `models_predict/`: Contém os modelos treinados serializados (arquivos `.joblib`).
- `report/`: Diretório destinado ao armazenamento de artefatos utilizados no relatório, como figuras, gráficos e tabelas geradas ao longo das análises.
- `src/`: Código-fonte principal do projeto.
  - `build_model.py`: Responsável pelo treinamento dos modelos.
  - `predict.py`: Responsável pela geração de previsões.
  - `utils.py`: Funções auxiliares utilizadas no projeto.
- `main.py`: Script principal que executa o pipeline do projeto.
- `README.md`: Documentação geral do projeto.
- `requirements.txt`: Lista de dependências do projeto.

2. Tratamento da base

Para o tratamento da base e geração do arquivo `SUPERSTORE_TRATADO.csv`, realizamos o seguinte processo:

1. Padronização de colunas string;
2. Eliminação de colunas irrelevantes (`CUSTOMER_NAME`, `POSTAL_CODE` e `ORDER_ID`);
3. Tratamento de colunas de datas;
4. Eliminação de registros inconsistentes e duplicados;
5. Tratamento de colunas de localização;
6. Criação da coluna `NET_SALES` pelo cálculo expresso abaixo:

$$\text{net_sales} = \text{sales} \times \text{quantidade} \times (1 - \text{desconto})$$

   e eliminação das colunas `SALES` , `QUANTITY` e `DISCOUNT`

Através deste processo de tratamento de dados, temos uma base ainda com bastante informação e pronta para eventuais análises exploratórias tanto dentro de um ambiente *Python* quanto em plataformas como: *Excel*, *Google Sheets*, *PowerBi* e *Google Looker*. Por fim, vale destacar que o tratamento da base está disponível em `utils.py`.

3. Análise exploratória

Disclaimer: Utilizamos predominantemente a biblioteca *plotly* PlotlyTechnologiesInc. (2015), que se destaca pela geração de gráficos interativos. Essa característica permite uma exploração mais aprofundada dos dados quando visualizados em um ambiente *Python*. Embora os principais *insights* sejam apresentados neste documento, recomendamos a consulta ao notebook `01_exploracao_inicial.ipynb` para uma análise mais completa e interativa das funcionalidades.

A. Evolução de vendas líquidas e lucro. Abaixo, temos dois gráficos que indicam, respectivamente, a evolução das vendas líquidas (`NET_SALES`) e do lucro ao longo do tempo. De maneira geral, em ambos observa-se um crescimento ao longo de 2019, seguido por oscilações nos anos seguintes, com picos pontuais tanto de vendas quanto de lucro.

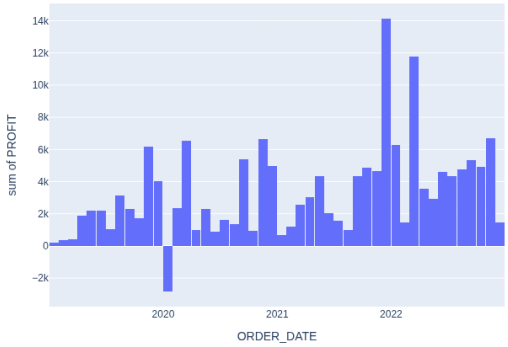

(a) Distribuição do lucro

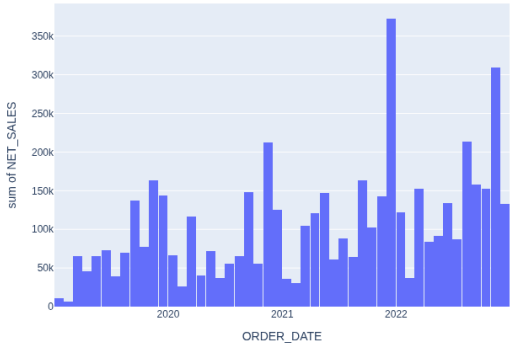

(b) Distribuição das vendas

Fig. 1. Distribuições de lucro e vendas

B. Lucro por localização geográfica. Em relação sa vendas por localização geográfica, temos que os estados de Nova Iorque e Califórnia são os estados com maior volume total de lucro, respectivamente U$ 41597.96 e U$ 35428.3872, enquanto os piores são: Illinois com U$ -8785.98 e Texas com -8517.6921.

Os que compõe a melhor média são Vermont(U$ 291.83) e Montana (U$ 200.90), enquanto os piores são West Virginia (U$ -36.94) e Illinois(U$ -31.83).

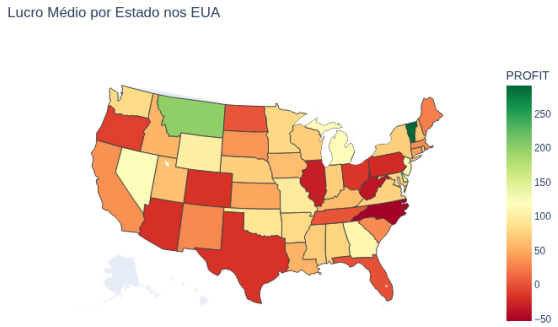

(a) Lucro médio por estado

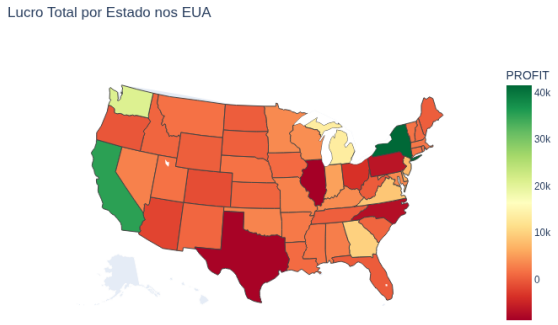

(b) Lucro total por estado

Fig. 2. Distribuição geográfica do lucro

C. Gráficos de Distribuição.

- **Lucro por categoria:** Tecnologia concentra a maior parcela do lucro (52,6%), seguida por Office Supplies (39,3%) e Furniture com participação reduzida (8,0%).

- **Lucro por região:** As regiões West (37,5%) e East (36,2%) lideram o lucro, enquanto South (14,8%) e Central (11,5%) apresentam menor contribuição.

- **Modo de envio:** O Standard Class é predominante (59,8%), seguido por Second Class (19,2%) e First Class (15,7%), com Same Day pouco utilizado (5,3%).

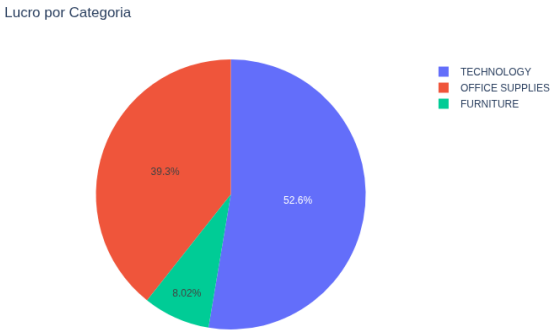

Fig. 3. Distribuição do lucro por categoria.

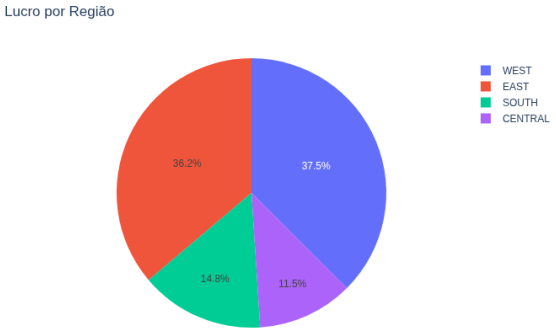

Fig. 4. Distribuição do lucro por região.

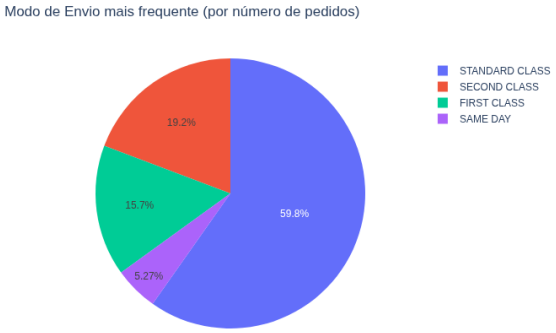

Fig. 5. Frequência dos modos de envio.

4. Modelagem

A. Clusterização.

A.1. Objetivo. O objetivo do processo de clusterização é traçar o perfil dos grupos de clientes que consomem na Superstore e compreender o padrão de consumo de cada um. Para uma análise mais precisa, torna-se necessário agrupar os clientes de acordo com seus padrões de consumo.

A.2. Pré-processamento. A partir do *dataset* tratado, `SUPERSTORE_TRATADO.csv`, realizamos a seguinte preparação para o processo de clusterização:

1. Seleção de colunas relevantes para clustering (`ORDER_DATE`, `SHIP_MODE`, `CUSTOMER_ID`, `SEGMENT`, `CATEGORY`, `REGION`, `NET_SALES`, `PROFIT`, `NET_SALES_SCALED` e `PROFIT_SCALED`.)

2. Agregação por cliente

3. Agrupamento por cliente e agregação de colunas relevantes

4. Preparação dos dados para clustering (*one-hot encoding*)

Assim como o tratamento anterior, o pré-processamento do modelo de base está disponível em `utils.py`.

A.3. Definição de parâmetros do modelo. O modelo utilizado para o processo de clusterização foi o kmeans disponível na biblioteca *Scikit-learn* Pedregosa et al. (2011). Para definir o número de clusters, analisamos as seguintes métricas: *Inertia*, *Silhouette Score*, *Calinski-Harabasz Index* e *Davies-Bouldin Index*. Os melhores valores de k para cada uma estão definidos na tabela abaixo:

Métricas	**Número de Clusters (k)**
Silhouette Score	3
Calinski–Harabasz	2
Davies–Bouldin	7
Elbow Method (método)	–

Table 1. Seleção do número de *clusters* por diferentes métricas

Além disso, obtivemos os seguintes gráficos:

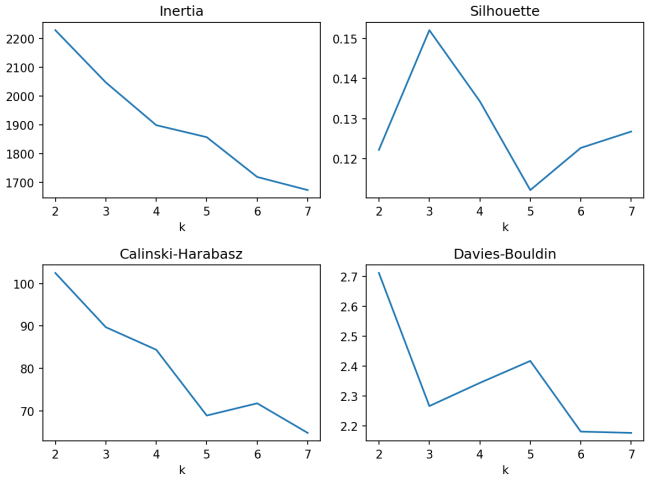

Fig. 6. Análise de diferentes métricas para definição do número de *clusters*

Note no gráfico, que apesar de termos diferentes valores na Tabela 1, temos que o valor mais próximo que entrega bons resultados é o número de *clusters* $k = 3$.

A.4. Aplicação do modelo. Aplicando o modelo, podemos observar a seguinte média de lucro (`PROFIT`) e vendas líquidas (`NET_SALES`) por cada grupo:

Cluster	Qtd. Clientes	Média Net Sales	Média Profit
0	395	868.46	56.02
1	229	889.33	56.64
2	146	722.67	49.42

Table 2. Estatísticas médias por cluster

Graficamente, obtemos:

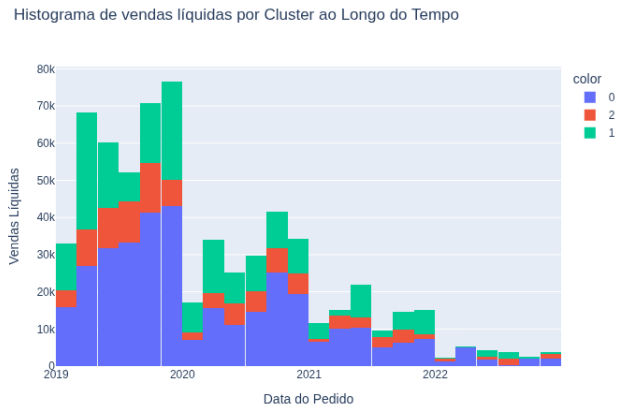

Fig. 7. Análise de diferentes métricas para definição do número de *clusters*

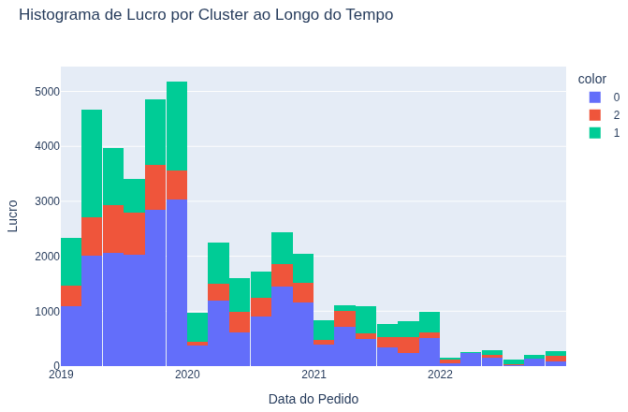

Fig. 8. Análise de diferentes métricas para definição do número de *clusters*

B. Predição.

B.1. Objetivo. A partir dos *clusters* definidos na seção anterior, construiremos um modelo de predição a partir de série temporal onde a variável *target* é a coluna `PROFIT`. Nosso objetivo é prever o lucro nos próximos meses com base no histórico disponibilizado.

B.2. Pré-processamento. Seguimos o seguinte procedimento para realizar a preparação da base para o modelo de predição

1. Preparação dos dados para análise temporal por *cluster*
2. Conversão da coluna `ORDER_DATE` para o tipo datetime
3. Agrupamento por mês e *cluster*, agregando o lucro total
4. Ordenação cronológica e filtragem dos dados para considerar apenas observações a partir de julho de 2020
5. Separação dos dados em subconjuntos por *cluster* (0, 1 e 2) e armazenamento dos subconjuntos em um dicionário indexado pelo *cluster*
6. Aplicação do teste de estacionariedade e ajuste da série (via diferenciação, se necessário

Um passo **fundamental** para o bom funcionamento do modelo foi a filtragem dos dados para considerar apenas observações a partir de julho de 2020. Observe os próximos gráficos:

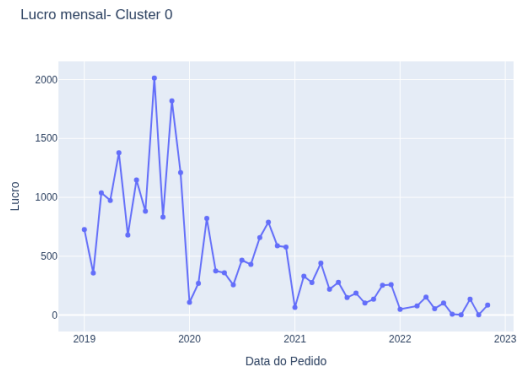

Fig. 9. Evolução do lucro mensal para o Cluster 0.

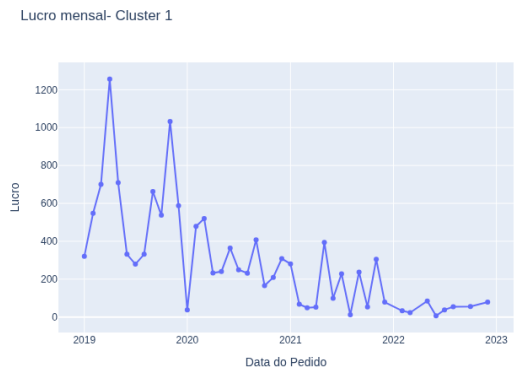

Fig. 10. Evolução do lucro mensal para o Cluster 1.

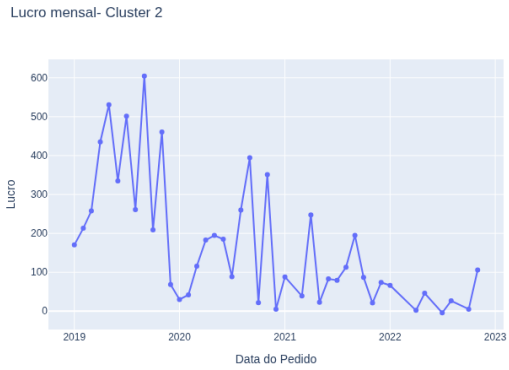

Fig. 11. Evolução do lucro mensal para o Cluster 2.

Note que há uma grande mudança no padrão de consumo em todos os **cluster** a partir de 2020. Portanto, optamos pela exclusão de dados anteriores à segunda metade de 2020 a fim de alimentar o modelo com um padrão de consumo mais próximo da data que queremos prever.

B.3. Aplicação do modelo. Para modelar, utilizamos o modelo ARIMA (*AutoRegressive Integrated Moving Average*) automático disponível na biblioteca *pmdarima* Smith et al. (17), por se tratar de uma série temporal. O uso deste modelo traz vantagens pelo fato de determinar automaticamente os valores ideais dos parâmetros melhorando o desempenho do modelo. Babu (2023). Os resultados estão expressos abaixo:

Assim como os tratamentos anteriores, o processo está salvo em `utils.py`.

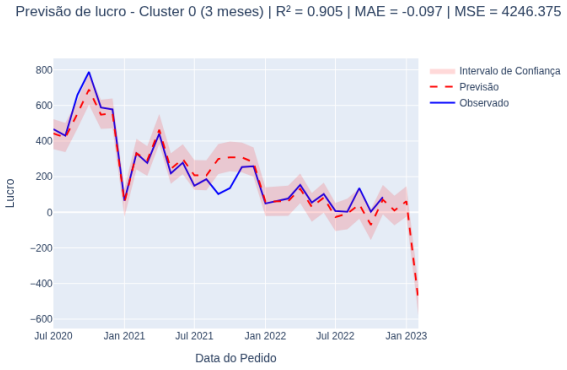

Fig. 12. Previsão do lucro mensal para o Cluster 0 com horizonte de 3 meses.

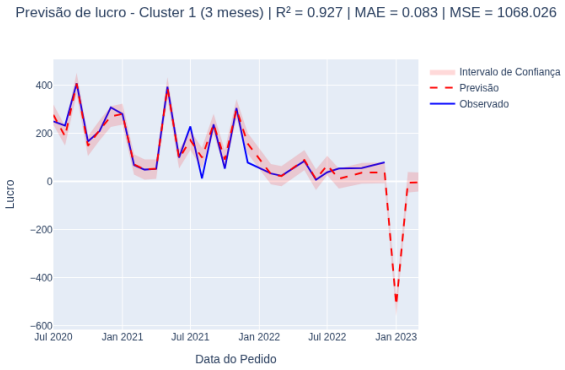

Fig. 13. Previsão do lucro mensal para o Cluster 1 com horizonte de 3 meses.

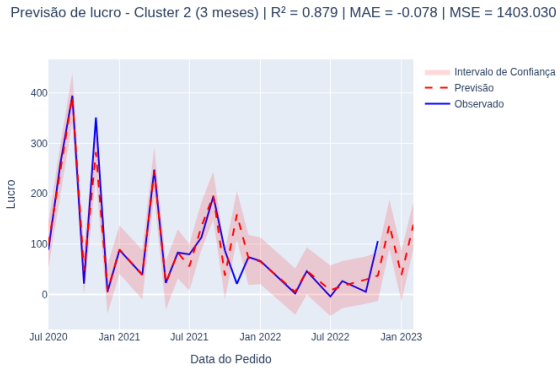

Fig. 14. Previsão do lucro mensal para o Cluster 2 com horizonte de 3 meses.

C. Conclusão e perspectivas. O trabalho contemplou o tratamento e a preparação da base de dados, a análise exploratória para identificação de padrões de vendas e lucro, a segmentação dos clientes por meio de clusterização e, por fim, a modelagem de séries temporais para previsão do lucro por grupo. Dessa forma, foi possível não apenas compreender o comportamento dos dados, mas também obter uma base consistente para apoiar a tomada de decisão.

References

Babu, A. (2023). A guide to time series forecasting in python. https://medium.com/@aditib259/a-guide-to-time-series-forecasting-in-python-b0b4529045db. Acessado em: 22 mar. 2026.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

PlotlyTechnologiesInc. (2015). Collaborative data science.

Smith, T. G. et al. (2017–). pmdarima: Arima estimators for Python. [Online; accessed 2026-03-22].

Wu, C. (n.d.). Superstore sales analysis dataset. https://raw.githubusercontent.com/WuCandice/Superstore-Sales-Analysis/refs/heads/main/dataset/Superstore%20Dataset.csv. Accessed: 2026-03-20.